

Análisis de Modelos No Supervisados

1. Cuadro comparativo los modelos no supervisados

A partir de la aplicación de los algoritmos K-Means y DBSCAN sobre el conjunto de datos (previa reducción de dimensionalidad mediante PCA), se identificaron las siguientes características comunes en los resultados obtenidos:

Cuadro 1: Características compartidas por los modelos no supervisados (K-Means y DBSCAN)

Característica	Descripción
Estructura limitada de agrupamiento	Ambos modelos muestran que los datos no presentan separaciones naturales claras, lo que dificulta la formación de clusters bien definidos.
Dependencia de la representación de datos	Los resultados dependen fuertemente del uso previo de PCA, ya que la reducción de dimensionalidad influye en la forma en que se agrupan los datos.
Escasa separación entre grupos	Los puntos tienden a concentrarse en regiones similares del espacio reducido, generando solapamiento entre clusters.
Sensibilidad a parámetros	Tanto K-Means (con k) como DBSCAN (con ε y <code>min_samples</code>) producen resultados distintos según los valores elegidos.
Distribución discreta de variables	La naturaleza discreta de las variables del dataset limita la formación de estructuras geométricas claras en el espacio de características.
Necesidad de escalamiento	Ambos métodos requieren normalización previa para evitar que ciertas variables dominen el análisis.
Uso exploratorio	Los dos modelos funcionan principalmente como herramientas exploratorias y no como métodos definitivos de segmentación en este caso.
Dificultad para interpretación clara	Ninguno de los modelos produce clusters fácilmente interpretables en términos de perfiles de crédito sin análisis adicional.

Interpretación

Ambos modelos no supervisados evidencian que el conjunto de datos no presenta una estructura de agrupamiento clara. Esto sugiere que las variables disponibles no permiten segmentar naturalmente a los individuos en grupos bien diferenciados, lo cual es consistente con la naturaleza compleja del riesgo crediticio. En consecuencia, estos métodos resultan más útiles como herramientas exploratorias que como soluciones definitivas para segmentación.

2. Características compartidas por los modelos no supervisados

Tras la aplicación de los algoritmos K-Means y DBSCAN sobre el conjunto de datos (utilizando previamente PCA para reducción de dimensionalidad), se identificaron patrones comunes en los resultados obtenidos.

En primer lugar, ambos modelos evidencian que el conjunto de datos no presenta una estructura de agrupamiento claramente definida. Los datos no se separan de forma natural en grupos bien diferenciados, lo que se refleja en la dispersión observada en el espacio reducido.

Asimismo, se observa que las variables del dataset, al ser en gran medida discretas y categóricas transformadas a valores numéricos, generan distribuciones concentradas en valores específicos, lo que limita la formación de clusters geoméricamente distinguibles.

Otro aspecto relevante es que ambos métodos muestran una alta dependencia de la representación de los datos. La aplicación de PCA influye directamente en la estructura observada, ya que la proyección a menor dimensión puede ocultar o distorsionar relaciones originales entre variables.

Adicionalmente, se identifica una sensibilidad significativa a los hiperparámetros. En el caso de K-Means, el número de clusters k afecta directamente la partición del espacio, mientras que en DBSCAN, los parámetros ε y el número mínimo de vecinos determinan la densidad requerida para formar agrupaciones.

Finalmente, ambos modelos coinciden en que el dataset no presenta agrupamientos naturales robustos, lo cual sugiere que el problema del riesgo crediticio no puede ser fácilmente abordado mediante segmentación no supervisada, sino que requiere modelos supervisados para una mejor discriminación entre clases.

Referencias

- [1] Amidi, A., & Amidi, S. (2018). *Super VIP Cheatsheet: Machine Learning*. Stanford University. (p. 6)
- [2] Jung, A. (2022). *Machine Learning: The Basics*. Springer. (p. 200)
- [3] Chan, S. H. (2021). *Introduction to Probability for Data Science*. Michigan Publishing. (p. 203)